

Atelier Pandas

Contexte

Une entreprise possède plusieurs bâtiments équipés de capteurs IoT.

Chaque capteur collecte régulièrement des informations sur la température, l'humidité, la pression, la consommation énergétique, l'état du capteur, le bâtiment, la date et l'heure de la mesure.

Les données doivent être préparées et analysées avant d'être transmises à un futur système de Machine Learning permettant de détecter des situations anormales.

Structure du projet

- 1) Structurer le projet comme suit :

```
atelier_pandas_iot/  
├── data/  
│   └── mesures_capteurs.csv  
├── notebooks/  
│   └── atelier_pandas_iot.ipynb  
└── exports/  
    ├── donnees_nettoyees.csv  
    └── donnees_nettoyees.json
```

- 2) Stocker le fichier fourni `mesures_capteurs.csv` dans le sous-dossier `data`

- 3) Créer le notebook `atelier_pandas_iot.ipynb`

NB : les fichiers du sous-dossier `exports` seront créés à la fin de l'atelier

Partie 1 – Series

- 1) Créer une Series contenant 4 températures
- 2) Afficher son index
- 3) Afficher la 1^{ère} valeur
- 4) Afficher la dernière valeur
- 5) Créer, de deux façon différentes, une Series de 4 températures avec comme index les heures de mesure 12h, 13h, 14h et 15h
- 6) Afficher la 1^{ère} et la dernière valeur

Partie 2 – DataFrame

- 1) Créer et afficher le dataframe `df_test` à partir du dictionnaire suivant

```
data = {  
    "capteur": ["C001", "C002", "C003"],  
    "temperature": [24.5, 25.1, 26.3],  
    "humidite": [65, 67, 70]  
}
```

- 2) Importer le dataset `mesures_capteurs.csv` dans le dataframe `df`
- 3) Afficher les dimensions de `df`

NB : dans la suite de l'atelier, on travaillera avec le dataframe `df`

Partie 3 – Exploration

- 1) Afficher les premières lignes
- 2) Afficher les 10 premières lignes
- 3) Afficher les dernières lignes
- 4) Afficher le nombre de lignes
- 5) Afficher le nombre de colonnes
- 6) Afficher les noms des colonnes
- 7) Afficher les informations générales
- 8) Afficher les statistiques descriptives

Partie 4 – Sélection

- 1) Sélectionner la colonne "temperature"
- 2) Sélectionner les colonnes "temperature", "humidite", "pression" et "consommation"
- 3) Sélectionner les 5 premières lignes avec **loc**
- 4) Sélectionner les 5 premières lignes et les 4 premières colonnes avec **iloc**

Partie 5 – Manipulation des colonnes

- 1) Ajouter la colonne "temperature_fahrenheit"
- 2) Ajouter la colonne "niveau_temperature" pour catégoriser la température en "Élevée" (température > 30) ou "Normale". On peut utiliser la méthode `where()` de numpy
- 3) Renommer la colonne "humidite" en "humidite_relative"
- 4) Supprimer la colonne "temperature_fahrenheit"

Partie 6 – Filtrage

- 1) Récupérer uniquement les lignes telles que température > 30
- 2) Récupérer uniquement les lignes telles que température > 30 et humidité > 70

Partie 7 : Tri

- 1) Créer **df_trie1** pour trier en fonction de la température croissante
- 2) Créer **df_trie2** pour trier en fonction de la température décroissante
- 3) Créer **top10** pour voir les 10 températures les plus élevées
- 4) Trier en fonction des colonnes "batiment" (croissant) et "temperature" (décroissant)

Partie 8 : Analyse

- 1) Afficher la consommation moyenne par bâtiment
- 2) Afficher le minimum, le maximum, la moyenne et l'écart-type de la température par bâtiment
- 3) Afficher, par bâtiment, le maximum et la moyenne de la température et de la consommation
- 4) Afficher la température moyenne globale
- 5) Afficher la température maximale
- 6) Afficher la consommation totale
- 7) Quel bâtiment consomme le plus en moyenne ?
- 8) Afficher le nombre d'alertes par bâtiment

Partie 9 : Gestion des valeurs manquantes

- 1) Afficher le nombre de valeurs manquantes par colonne
- 2) Afficher le nombre total des valeurs manquantes
- 3) Afficher le taux de valeurs manquantes
- 4) Afficher les lignes contenant des valeurs manquantes
- 5) Pour la température et l'humidité, remplacer les valeurs manquantes par les moyennes
- 6) Pour la consommation, remplacer les valeurs manquantes par la médiane

- 7) Pour "etat", remplacer les valeurs manquantes par "INCONNU"

Partie 10 : Gestion des doublons

- 1) Afficher le nombre de doublons
- 2) Afficher les doublons
- 3) Supprimer les doublons puis vérifier la suppression

Partie 11 : Statistiques descriptives

- 1) Pour la température, afficher le minimum, le maximum, la moyenne, la mediane, l'écart-type et le nombre de valeurs
- 2) Pour "etat", afficher le mode et le nombre de mesures par état (OK, ALERTE, ERREUR)

Partie 12 : Exportation

- 1) Exporter le dataframe nettoyé dans **exports/donnees_nettoyees.csv**
- 2) Exporter le dataframe nettoyé dans **exports/donnees_nettoyees.json**

Partie 13 : Bonus

Proposer et réaliser toute fonctionnalité pertinente et utile qu'on pourrait rajouter à l'atelier.

Livrable attendu

Chaque apprenant devra fournir le dossier **atelier_pandas_iot**

Modalité de livraison

Chaque apprenant pousse

- 1) le livrable, **d'abord vide**, sur un dépôt public de son compte Github personnel
- 2) met à jour le livrable, au fur et à mesure, avec des messages de commit explicites